

Oblig 5

ITD20218-1 25V Statistikk og statistisk programmering

Andreas Isaksen

20. mars 2025
Halden



Innhold

1	Innlevering	1
1.1	Oppgave 1	1
1.2	Oppgave 2	3
1.3	Oppgave 3	5
1.4	Oppgave 4	6
1.5	Oppgave 5	8
1.6	Oppgave 6	10
1.7	Oppgave 7	10

Innlevering

1.1 Oppgave 1

Denne oppgaven skal løses uten bruk av Python.

Vanlig kjøttdeig skal ikke inneholde mer enn 14% fett. Vi har mistanke om at kjøttdeig inneholder for mye fett, og bestemmer oss for å utføre en hypotesetest. La X være prosentandelen fett i en tilfeldig 400g pakke kjøttdeig. Vi antar at X er normalfordelt med forventningsverdi μ og standardavvik $\sigma = 3$.

a) Formuler hypotesene.

Vi skal teste sannsynligheten for at en pakke kjøttdeig inneholder mer enn 14% fett.

Antar at fett prosent på en tilfeldig pakke er: $\sim N(\mu, \sigma)$

X : Fettprosent i en tilfeldig pakke.

$$X \sim N(\mu, \sigma)$$

Da må gjennomsnittet på prosentandelen ($\bar{X}$) være:

$$\bar{X} \sim N(\mu, \frac{\sigma}{\sqrt{n}})$$

Hypoteser:

- H_0 : En pakke inneholder ikke mer enn 14% fett:

$$H_0 : \mu \leq \mu_0 = \mu \leq 14$$

- H_1 : En pakke inneholder mer enn 14% fett:

$$H_1 : \mu > \mu_0 = \mu > 14$$

b) Utfør testen med signifikansnivå 0.05 når vi har følgende målinger:

14, 15, 18, 12, 17, 13, 15, 19, 16

- $n = 9$
- $\alpha = Z_{0.05} = 1.645$
- Vi er nødt til å finne snittet før vi kan regne ut testobservasjonen.

$$\bar{X} = \frac{x_1 + \dots + x_9}{9} = 15.44$$

Test observator:

$$z = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{15.44 - 14}{\frac{3}{3}} = 1.44$$

$$z = 1.44 < z_{0.05} = 1.645$$

Vi kan ikke forkaste H_0 på signifikansnivå 0.05

Vår undersøkelse viser at fettprosenten på tilfeldig valgte pakker ikke vil overstige 14%

c) Beregn testens p -verdi.

$$p = (X > \bar{x}) = 1 - G\left(\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}\right)$$

$$p = (X > 15.44) = 1 - G\left(\frac{15.44 - 14}{\frac{3}{3}}\right) = 1 - G(1.44) = 1 - 0.9251 = \underline{\underline{0.0749}}$$

d) Beregn testens styrkefunksjon for verdiene 13, 14, 15, 16 og 17 og skisser den.

$$\gamma(\mu) = P(\text{Fett\% er over } 14) = P(\bar{X} \geq k) = 1 - P(\bar{X} \leq k)$$

$$= 1 - P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \frac{k - \mu}{\sigma/\sqrt{n}}\right) = 1 - P\left(Z \leq \frac{k - \mu}{\sigma/\sqrt{n}}\right) = 1 - G\left(\frac{k - \mu}{\sigma/\sqrt{n}}\right) = 1 - G\left(Z_\alpha - \frac{\mu - \mu_0}{\sigma/\sqrt{n}}\right)$$


$$\gamma(13) = 1 - G\left(1.645 - \frac{13 - 14}{3/3}\right) = 1 - G(2.645) = 1 - 0.99595 = \underline{\underline{0.00405}}$$

$$\gamma(14) = 1 - G\left(1.645 - \frac{14 - 14}{3/3}\right) = 1 - G(1.645) = 1 - 0.95 = \underline{\underline{0.05}}$$

$$\gamma(15) = 1 - G\left(1.645 - \frac{15 - 14}{3/3}\right) = 1 - G(0.645) = 1 - 0.74055 = \underline{\underline{0.25945}}$$

$$\gamma(16) = 1 - G\left(1.645 - \frac{16 - 14}{3/3}\right) = 1 - G(-0.355) = 1 - 0.3613 = \underline{\underline{0.6387}}$$

$$\gamma(17) = 1 - G\left(1.645 - \frac{17 - 14}{3/3}\right) = 1 - G(-1.355) = 1 - 0.0877 = \underline{\underline{0.9123}}$$



Figur 1.1: Skisse av styrkefunksjon

- e) Vi krever at sannsynligheten for type II feil skal være mindre enn 0.10 når $\mu = 16$.
Hvor mange målinger må vi foreta for å oppnå denne styrken?

Om vi forsøker å doble antallet pakker vi kontrollerer, burde vi kunne få bedre data for å redusere sannsynligheten for antall feil når $\mu = 16$

$$n = 18$$

$$\gamma(16) = 1 - G\left(1.645 - \frac{16 - 14}{3/\sqrt{18}}\right) = 1 - G(-1.1834) = 1 - 0.1190 = 0.881$$

Når vi øker antallet kontroller til 18 kan vi se at sannsynligheten for feil med $\mu = 16$ øker til 88.1%, som tilsvarer en sannsynlighetsfeil av type II på 11.9%. Siden dette ikke innfrir kravet, må vi øke antallet forsøk.

$$n = 20$$

$$\gamma(16) = 1 - G\left(1.645 - \frac{16 - 14}{3/\sqrt{20}}\right) = 1 - G(-1.3364) = 1 - 0.09095 = \underline{\underline{0.90905}}$$

Når vi øker antallet kontroller til 20 kan vi se at sannsynligheten for feil med $\mu = 16$ øker til 90.905%, som tilsvarer en sannsynlighetsfeil av type II på 9.095%. Dette innfrir kravet til kvalitetskravet for undersøkelsen.

1.2 Oppgave 2

Denne oppgaven skal løses uten bruk av Python (med unntak av spørsmål c).

Denne oppgaven er til forveksling lik den foregående, men nå er standardavviket ukjent.

Dessuten skal vi ha et annet signifikansnivå og litt andre målinger. Videre dropper vi spørsmålene om styrkefunksjon (fordi det blir litt komplisert i dette tilfellet).

Vanlig kjøttdeig skal ikke inneholde mer enn 14% fett. Vi har mistanke om at kjøttdeig inneholder for mye fett, og bestemmer oss for å utføre en hypotesetest. La X være prosentandelen fett i en tilfeldig 400g pakke kjøttdeig. Vi antar at X er normalfordelt med forventningsverdi μ og ukjent standardavvik σ .

a) Formuler hypotesene.

Vi skal teste sannsynligheten for at en pakke kjøttdeig inneholder mer enn 14% fett.

Antar at fett prosent på en tilfeldig pakke er: $\sim N(\mu, \sigma)$

X : Fettprosent i en tilfeldig pakke.

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Hypoteser:

- H_0 : En pakke inneholder ikke mer enn 14% fett:

$$H_0 : \mu \leq \mu_0 = 14$$

- H_1 : En pakke inneholder mer enn 14% fett:

$$H_1 : \mu > \mu_0 = 14$$

b) Utfør testen med signifikansnivå 0.01 når vi har følgende målinger:

15, 17, 18, 14, 19, 16, 17, 15, 19, 13

- Her brukes t -test fordi σ er ukjent.
- $\alpha = 0.01$
- $n = 10$
- $\gamma = n - 1 = 10 - 1 = 9$
- $\bar{X} = \frac{15+17+18+14+19+16+17+15+19+13}{10} = 16.3$
- Finner standardavviket(S):

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$$

$$S^2 = \frac{1}{9} \sum_{i=1}^9 (x_i - 16.3)^2 \approx 4.233333$$

$$S = \sqrt{S^2} = \sqrt{4.233333} \approx 2.05751$$

- **Testobservator, t :**

$$t = \frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}$$

$$t = \frac{16.3 - 14}{\frac{2.05751}{\sqrt{10}}} = \frac{2.3}{0.65064} \approx 3.53498$$

- Finner **kvantilet** fra tabell:

$$t_{\alpha,\gamma} = t_{0.01,9} = 2.821$$

- Her er $t = 3.53498 > t_{0.01,9} = 2.821$

- **Konklusjon:**

Vi kan forkaste H_0 på signifikansnivå 0.01. Observasjonene tyder på at fettprosenten er for høy.

- c) Bruk en tabell til å finne et anslag for testens p -verdi (vi kan ikke finne den eksakte verdien fra våre tabeller). Bruk også Python til å finne den eksakte verdien ved hjelp av `scipy.stats.t`-funksjonen.

$$t = 3.53498$$

- $t_{0.01,9} = 2.821$
- $t_{0.005,9} = 3.250$
- $t_{0.0005,9} = 4.781$

$$3.250 < 3.53498 < 4.781$$

Basert på dette kan vi anta at p -verdien ligger mellom signifikansnivå 0.005–0.0005 med frihetsgrad 9.

Kode 1.1: Vedlagt kode: oppg2c.py

```
import scipy.stats as s

print(1 - s.t.cdf(3.535, 9))
```

Kode 1.2: Konsoll print

```
0.0031819100017240753
```

1.3 Oppgave 3

Denne oppgaven skal løses uten bruk av Python.

Et legemiddelfirma har utviklet et nytt medikament til behandling av pasienter med Alzheimers sykdom. Eksisterende medikamenter har en nytteeffekt hos 55% av pasientene. Legemiddelfirmaet påstår at det nye medikamentet er bedre enn de eksisterende. For å teste hypotesen blir 45 pasienter behandlet med det nye medikamentet. Totalt X av disse vil oppleve nytte av medisinen. Vi kan anta at variabelen X er binomisk fordelt med ukjent parameter p .

Testen av det nye medikamentet viste at 35 av de 45 pasientene hadde nytte av behandlingen. Utfør en hypotesetest med signifikansnivå 0.05.

- X : Pasient har nytte av medikamentet

- $N = 45$
- $\alpha = 0.05$
- $\hat{p} = \frac{35}{45} = \frac{7}{9}$

Hypoteser:

- $H_0 = p \leq 0.55$ – Nytt medikament er ikke bedre.
- $H_1 = p > 0.55$ – Nytt medikament er bedre.

Sjekker forutsetning ($n\hat{p}(1 - \hat{p}) \geq 5$)

$$45 \cdot \frac{7}{9} \left(1 - \frac{7}{9}\right) = \frac{70}{9} \approx 7.778$$

$$7.778 > 5 \quad \underline{\hat{p} \text{ er ok}}$$

Testobservator for binomisk fordeling ($X \sim \text{bin}(n, p)$):

$$z = \frac{x - np_0}{\sqrt{np_0(1 - p_0)}} = \frac{35 - 45 \cdot 0.55}{\sqrt{45 \cdot 0.55(1 - 0.55)}} = \frac{10.25}{\sqrt{11.1375}} \approx 3.0714$$

$$z = 3.0714 > z_{0.05} = 1.6449$$

Kan forkaste H_0 på signifikansnivå 0.05

Undersøkelsen viser at nye medikamenter har gode nok resultater til at de kan anbefales som et nytt alternativ basert på denne undersøkelsen.

1.4 Oppgave 4

Lag et Python-program som utfører en hypotesetest basert på følgende scenario.
(Tips: du kan bruke funksjonen `scipy.stats.ttest_1samp` i denne oppgaven.)

På den greske øya Kripos kryr det av villkatter. Man antar at mange turister mater kattene når de sitter og spiser. Man ønsker derfor å undersøke om vekten til kattene er høyere på slutten av turistsesongen enn ellers i året.

Anta at vekten til voksne katter på Kripos før turistsesongen har begynt, er normalfordelt med forventningsverdi $\mu = 2.75$ kg.

For å undersøke om vekten har økt i løpet av turistsesongen, veier man en del katter på slutten av turistsesongen. Resultatet av målingene finner du i følgende fil:

http://www.it.hiof.no/statok/katters_vekt.csv

De fire feltene i filen er: løpenummer, kjønn, kattens vekt i kg og hjertets vekt i gram.

a) Angi i besvarelsen hypotesene du bruker.

- $H_0 = \mu \leq \mu_0$ – Kattenes vekt er ikke større etter turistsesongen.
- $H_1 = \mu > \mu_0$ – Kattenes vekt er større etter turistsesongen.

Hypotese er bakket inn i Python kode på tilhørende oppgave("oppg4.py").

b) Utfør en hypotesetest ved å beregne testobservatoren t og sammenligne den med kvantilet i t -fordelingen for å finne ut om undersøkelsene gir belegg for å hevde at forventningsverdien til kattenes vekt har øket i løpet av turistsesongen.

Programmet skal be om signifikansnivå «alfa» og forventningsverdien «my_0». «my_0» er altså den forventningsverdien til vekten som vi skal sjekke mot, altså **2.75** i vårt tilfelle: Er forventningsverdien til kattenes vekt høyere enn **2.75** på slutten av turistsesongen?

Denne løsningen ligger i Python kode på tilhørende oppgave("oppg4.py").

c) Finn testens p -verdi og skriv den ut.

Denne løsningen ligger i Python kode på tilhørende oppgave("oppg4.py").

d) Kjør programmet flere ganger og finn hvilket signifikansnivå som gjør at vi går fra å beholde H_0 til å forkaste H_0 . Sammenlign med p -verdien.

- $\alpha = 0.001$
- $t = 3.16017$

$$t = 3.16017 < t_{0.001,96} = 3.17731$$

- $p\text{-verdi} \approx 0.0021095$

Kan ikke forkaste H_0 på dette signifikansnivå.

$$p\text{-verdi} = 0.0021095 > \alpha = 0.001$$

Vi beholder H_0 ved å teste p -verdi på signifikansnivå 0.001

e) Undersøk ved å kjøre programmet med ulike verdier av my_0 hvilken my_0 som er grensa mellom å forkaste H_0 og beholde H_0 når vi gjør hypotesetest på signifikansnivå $\sigma = 0.05$.

Grensen for om om beholder eller forkaster H_0 ligger mellom $\mu[2.82, 2.83]$

Kode 1.3: Konsoll utskrift på testing av μ

```
%runfile oppg4.py --wdir
a)
Påstand: Katters vekt er høyere etter turistperioden.
Hypotese:
H0:  $\mu \leq \mu_0$  -- Kattenes vekt er ikke større etter turistsesongen.
H1:  $\mu > \mu_0$  -- Kattenes vekt er større etter turistsesongen.
```

```

Signifikatsnivå?(standard=0.05):
Forventningsverdi?(standard=2.75): 2.83
b)
Her er  $t=1.47474 < t_{\alpha, \gamma}=1.66088$ 
Koklusjon: Vi kan ikke forkaste  $H_0$  på signifikansnivå 0.05.
Obeservasjonene tyder på at katter ikke er tyngre etter turistsesongen
c)
Testens p-verdi: 0.14355329378536152

%runfile oppg4.py --wdir
a)
Påstand: Katters vekt er høyere etter turistperioden.
Hypotese:
 $H_0: \mu \leq \mu_0$  -- Kattenes vekt er ikke større etter turistsesongen.
 $H_1: \mu > \mu_0$  -- Kattenes vekt er større etter turistsesongen.
Signifikatsnivå?(standard=0.05):
Forventningsverdi?(standard=2.75): 2.82
b)
Her er  $t=1.68542 > t_{\alpha, \gamma}=1.66088$ 
Koklusjon: Vi kan forkaste  $H_0$  på signifikansnivå 0.05.
Obeservasjonene tyder på at katter er tyngre etter turistsesongen
c)
Testens p-verdi: 0.09515514601836511

```

1.5 Oppgave 5

Følgende oppgave skal løses uten bruk av Python.

I tabellen nedenfor har jeg plukket ut data for noen få av kattene fra oppgave 4.

Katten vekt(kg)	2	2.4	2.6	3.2	3.6
Hjertets vekt(g)	6.5	7.9	8.3	11.9	13.3

Beregn den empiriske korrelasjonskoeffisienten r mellom disse kattene vekt og vekten av deres hjerter.

$$\cdot n = 5$$

$\underline{x}$	$\underline{y}$	$\underline{x - \bar{x}}$	$\underline{y - \bar{y}}$	$\underline{(x - \bar{x})^2}$	$\underline{(y - \bar{y})^2}$	$\underline{(x - \bar{x})(y - \bar{y})}$
2	6.5	-0.76	-3.08	0.5776	9.4864	2.3408
2.4	7.9	-0.36	-1.68	0.1296	2.8224	0.6048
2.6	8.3	-0.16	-1.28	0.0256	1.6384	0.2048
3.2	11.9	0.44	2.32	0.1936	5.3824	1.0208
3.6	13.3	0.84	3.72	0.7056	13.8384	3.1248
$\bar{x} = 2.76$	$\bar{y} = 9.58$			$\sum = 1.632$	$\sum = 33.168$	$\sum = 7.296$

Med denne tabellen kan vi finne r

- Estimator for $Cor(x, y) = S_{xy}$

$$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

$$S_{xy} = \frac{1}{4} \cdot 7.296 = 1.824$$

- Estimator for $\sigma_x = S_x$ og $\sigma_y = S_y$

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$S_x^2 = \frac{1}{4} \cdot 1.632 = 0.408$$

$$S_y^2 = \frac{1}{4} \cdot 33.168 = 8.292$$

$$S_x = \sqrt{S_x^2} = \sqrt{0.408} \approx 0.63875$$

$$S_y = \sqrt{S_y^2} = \sqrt{8.292} \approx 2.87958$$

- Definerer r

$$r = \frac{S_{xy}}{S_x \cdot S_y} = \frac{1.824}{0.63875 \cdot 2.87958} \approx \underline{\underline{0.9917}}$$

- Her kan vi se at $|r|$ er svært nærme positiv 1. Dette indikerer at det er en sterk positiv korrelasjon mellom vekten til katten og hjertet.

1.6 Oppgave 6

Lag et Python-program som beregner og skriver ut den empiriske korrelasjonskoeffisienten r mellom kattens vekt og vekten av deres hjerter, basert på hele datasettet

http://www.it.hiof.no/statok/katters_vekt.csv.

Funksjonen `scipy.stats.pearsonr` kan brukes til dette.

Angi i besvarelsen hvilken verdi for r du finner.

(Korrelasjonskoeffisienten r kalles ofte Pearsons korrelasjonskoeffisient, oppkalt etter den engelske matematikeren Karl Pearson. Det er derfor `scipy`-funksjonen for å beregne den heter «`pearsonr`». Korrelasjonskoeffisienten r er selvsagt oppkalt etter Pearson siden det var Bravais og Galton som først definerte denne $\dots$).

Denne løsningen ligger i Python kode på tilhørende oppgave("oppg6.py").

1.7 Oppgave 7

I denne oppgaven skal du bruke Python kun i spørsmål e.

I forbindelse med Vinmonopolets lansering av årets viner fra Burgund for noen år siden, sto det en artikkel i nettavisen «Børsen». (Du kan finne den her hvis du er interessert:

<https://www.borsen.no/livsstil/skremt-etter-vinavsloring---skandale/72102130>.)

I artikkelen fortelles det at det ble åpnet 74 vinflasker, og at 11 av disse var «korket», altså at vinen hadde blitt helt eller delvis ødelagt på grunn av luftlekkasje i korken. Dette var en overraskende stor feilprosent. Ifølge artikkelen er det vanlige at 5% av flaskene har slike feil.

- a) Anta at man før starten av denne prøvesmakingen trekker ut en tilfeldig flaske av de 74 flaskene. Hva er sannsynligheten for at denne flasken har korkfeil?

$$p = \frac{11}{74} \approx \underline{\underline{0.1486}}$$

- b) Hvis vi i utgangspunktet trekker ut 10 av de 74 flaskene, hva er sannsynligheten for at nøyaktig 5 av disse har korkfeil?

- $N = 74$
- $M = 11$
- $n = 10$
- X : Antall korkede flasker.
- $X \sim \text{hypergeom}(N, M, n)$

$$P(X = 5) = \frac{\binom{11}{5} \binom{74-11}{10-5}}{\binom{74}{10}} \approx \underline{\underline{0.0045}}$$

Den ansvarlige i Vinmonopolet kommer i artikkelen med følgende uttalelse:

«Jeg tror det var ganske tilfeldig at det dukket opp så vidt mye korkfeil.»

Vi skal undersøke dette ved hjelp av en hypotesetest.

- c) For at vi skal kunne bruke den standardnormalfordelte testobservatoren Z til hypotesetesten, må det stilles et krav til variansen (se regel 6.21, s. 273 i Løvås). Undersøk om dette kravet er oppfylt i dette tilfellet.

– Kontrollerer om X er tilnærmet normalfordelt

– $n = 74$

– $\hat{p} = \frac{11}{74}$

$$n\hat{p}(1 - \hat{p}) > 5$$

$$74 \cdot \frac{11}{74} \left(1 - \frac{11}{74}\right) > 5$$

$$9.3649 > 5$$

$\hat{p}$ er ok.

- d) Uansett om du i spørsmål c fant at kravet var oppfylt eller ikke, skal du gjennomføre en hypotesetest for å vurdere om uttalelsen fra den ansvarlige i Vinmonopolet er en rimelig uttalelse. Benytt signifikansnivå **0.1**. Det du skal undersøke er altså om det er rimelig å anta at de **74** flaskene som ble åpnet faktisk kan være et tilfeldig utvalg fra en populasjon med maksimum 5% feil.

· X : Flaske har korkfeil.

· $n = 74$

· $\alpha = 0.1$

· $p_0 = 0.05$

· $\sim \text{bin}(n, p)$

Hypoteser:

– $H_0 = p \leq 0.05$ – Ikke over 5% korkfeil

– $H_1 = p > 0.05$ – Over 5% korkfeil

Forutsetning for $\hat{p}$ ble kontrollert ok i oppgave c).

– $x \sim \text{bin}(n, p)$

– **Testobservator**

· $\alpha = 0.1$

· $z_{0.1} = 1.282$

$$z = \frac{x - np_0}{\sqrt{np_0(1 - p_0)}} = \frac{11 - 74 \cdot 0.05}{\sqrt{74 \cdot 0.05(1 - 0.05)}} = \frac{7.3}{\sqrt{3.515}} \approx 3.89368$$

$$z = 3.89368 > z_{0.1} = 1.282$$

Vi kan forkaste H_0 på signifikansnivå 0.1

Basert på gitte data, indikerer vår undersøkelse at over 5% av flaskene vil ha korkefeil.

- e) Et alternativ til å gjennomføre en hypotesetest basert på Z , er å benytte den eksakte p -verdien utregnet på bakgrunn av at dette er en binomisk fordeling. Bruk Python og finn den eksakte p -verdien, og gjør en hypotesetest basert på denne.

Kode 1.4: Vedlagt kode: oppg7e.py

```
from scipy.stats import binom as b

n = 74
x = 11
p0 = 0.05

p_value = b.sf(x-1, n, p0)

print(round(p_value, 8))
```

Kode 1.5: Print til konsoll

```
0.00110097
```

- $p\text{-verdi} = 0.00110097$
- $\alpha = 0.1$

$$0.00110097 < 0.1$$

Siden p -verdien er så lav forkaster vi H_0 på signifikansnivå 0.1